

훈수안이조

주요 방산 전자부품 수출입 및 국산화 현황 대시보드

전처리 보고서

문서 일자 2026-10-04

훈수안이조 · 과정 가이드 산출물 ④ 「전처리 및 EDA 보고서」 중 전처리 편(EDA 편은 08_EDA_보고서)

이 문서는 정제 노트북 01~06 과 EDA 노트북 11 · 13 의 **저장된 실행 결과를 모은 요약**이며, 새로 계산한 값은 없다. 근거 셀은 괄호에 적었다 — 「04 [15]」는 04_clean_domestic.ipynb 의 맨 위 셀을 [0] 으로 센 15번 셀(마크다운 셀 포함)이다. 원본 노트북은 Google Drive 1조 공유 폴더의 3번(데이터 전처리) · 4번(데이터 분석 EDA) 폴더와 GitHub 저장소 notebooks/ 에 있고, 모두 실행 결과가 저장돼 있어 다시 실행하지 않고 읽을 수 있다.

목차

1. 원칙

2. 데이터별 처리 요약

3. 핵심 2종의 단계별 건수

4. 유형별 처리 사례

5. 제외 행과 사유

6. 한계와 남은 과제

7. 부록 — 노트북 색인

1. 원칙

정제 노트북 여섯 개는 같은 네 원칙을 따른다(규칙 문서 docs/reference/data-cleaning-rules.md §1, 각 노트북 [0] 셀의 「원칙」).

원칙	하는 일	근거 셀
원본 불변	내려받은 원본 파일은 고치거나 지우지 않고 DB 에도 넣지 않는다. 노트북은 파일을 읽기만 하고, 결과는 별도의 정제 표(clean_*)에 쓴다. 정제 행마다 원본 행 번호(raw_row_id)를 남겨 원본 행을 되짚을 수 있다. 원본의 결함도 원본에서 고치지 않고 정제 단계에서 바로잡는다	01 [0] · 06 [0]
결측은 추정하지 않는다	비어 있는 값은 0 이나 그럴듯한 값으로 채우지 않고 NULL(비어 있음)로 둔다. 근거가 없는 표준명 · 시도 · 분류는 만들지 않고 「미확인」 · 「판단 보류」로 남긴다	04 [0] · 03 [0]
원본 = 정제 + 제외	정제 표에서 뺀 원본 행은 사유와 함께 제외 기록 표(clean_excluded_row)에 남기고, 데이터마다 「원본 행 수 = 정제 행 수 + 제외 행 수」를 계산한다(차이 = 0)	01 [21] · 03 [16] · 04 [15] · 05 [13] · 06 [9]
단계별 건수 기록	「원본 전체 → 선택 연도 → 중복 처리 후 → 관련 후보 → 검증된 분석 대상」 순서로 건수를 적재 기록 표(meta_load_log)에 남긴다	01 [20] · 05 [13] · 06 [9]

하나 더 — 노트북은 **판단이 필요한 속성을 만들지 않는다**. 전자 여부 · 계약 5분류처럼 사람이 검수해야 하는 열은 기본값(「미확인」 · 「판단 보류」)으로 두고, 키워드로 고른 값은 「후보」 · 「잠정」이라고 표시한다(02 [0] · 04 [0]).

2. 데이터별 처리 요약

행 수는 모두 노트북 출력 그대로다. 「제외 행」은 정제 표에 넣지 않은 원본 행이고, 빠지 않고 표시만 한 행은 「핵심 규칙」에 적었다.

데이터	원본 행	정제 행	제외 행	핵심 규칙	노트북(셀)
관세청 품목별 · 국가별 수출입실적	294,420	294,174	246 (연간 총계행)	총계행 분리 · 금액 단위(달러) 판정 · 연월 분리. 총계행과 상세행 합계 대조 불일치 0	01 [3]~[5] · [21]
무역안보관리원 HSK 연계표	2,161 (HSK10)	10,104 (HSK10 × 통제번호)	0	심표로 묶인 통제번호 목록을 1행 1통제번호로 분해. 같은 HSK10 안 중복 통제번호 29개는 1개만	01 [14] · [21]
관세청 HS부호 마스터	12,469	11,327 (10자리)	—	7~10자리가 섞여 있어 10자리 행만 기준표로 쓴다. 빈 열(hs_desc 12,469행 전부 공란)은 옮기지 않는다	01 [9]
방위사업청 국산화개발품목	33,965	25,025	0	업무키(사업명 × 부품관리번호)로 완전 중복 8,940행을 축약하고 원본 행 수(dup_count)를 보존. 군급(FSC)이 4자리가 아닌 16행은 군급만 NULL	02 [3]~[4] · 13 [7]~[9]
국외조달 조달계획(파일판)	3,029	3,023	1 + 5	판단번호 단위. 필수값 결측 1행, 같은 판단번호의 별개 계획 5쌍 중 대표가 아닌 행	02 [5]~[6]
국외 조달계획 OpenAPI(품목 단위)	13,615	13,615	0	재고번호(NSN) 형식 판별 · 군 이름 표준화 · 금액은 통화 미검증이라 합산 금지	03 [3]~[4]~[16]
국외조달 계약정보	6,333	6,327	6	업체명이 정확히 TEST2 인 테스트 계약만 제외	03 [8]~[16]
국외조달 입찰결과	2,494	2,494	0	4열 조합으로 고유. 개찰 2025-03~09 부분연도 표시	03 [10]~[16]

데이터	원본 행	정제 행	제외 행	핵심 규칙	노트북(셀)
국내조달 계약정보	43,112	43,105	7	계약차수 2자리 통일 · 최종 차수 표시. 키 충돌 1 · 테스트 업체 6	04 [3]·[15]
국내조달 입찰공고	10,842	10,840	2	열 밀림 행 제외	04 [5]·[15]
국내조달 입찰결과	7,405	7,403	2	열 밀림 행 제외. 같은 키의 여러 행은 지우지 않고 유형 표시	04 [7]·[15]
국내 조달계획	35,859	35,859	0	원본과 1:1. 예산 미기재 4,965행은 NULL	04 [9]·[15]
군별 계약집행 · 방산업체 지정현황	40 · 84	40 · 84	0	원본과 1:1	04 [15]
KRIT 부품국산화 공고	96	96	0	과제번호 재부여 · 정부지원금 억 원으로 통일	05 [3]·[13]
열린재정 세부사업 예산	2,860	2,860	0	천 원 문자열 → 정수 + 억 원 열. 정부안만 있는 2027년은 「미확정」 표시	05 [5]·[13]
KOSIS 방산 가동률 · 광공업생산지수	81 · 1,016	81 · 1,016	0	원본과 1:1. 잠정치 · 부분연도 표시, 지수와 금액은 합산하지 않음	06 [3]·[5]·[9]

3. 핵심 2종의 단계별 건수

과정 요건의 1만 건 데이터 2종은 관세청 수출입실적과 국산화개발품목이다. 두 데이터가 원본에서 분석 대상까지 줄어드는 과정은 아래와 같다. 그림은 노트북에 저장된 단계별 건수를 다시 그린 것이며 새로 계산한 값은 없다.




그림 1. 핵심 2종의 단계별 행 수 — 저장된 건수를 다시 그린 그림(출처: 11_eda_customs [5] · 13_eda_localized_item [9])

단계	관세청 수출입실적	줄어든 이유	국산화개발품목	줄어든 이유
① 원본 전체	294,420	—	33,965	—
②	294,174	연간 총계행 246행 분리(01 [3])	25,025	완전 중복 8,940행 축약, 업무키 충돌 0(13 [7])

단계	관세청 수출입실적	줄어든 이유	국산화개발품목	줄어든 이유
③	276,362	2026년(1~8월) 부분연도 제외 — 완결연도 2016~2025	25,009	군급 0 15행 · 결측 1행(13 [7])
④	146,817	분석 대상 13개 HS6(수집 24개 중 우선순위 1 · 2)	2,717	전자 계열 군(FSG 58 · 59 · 60)
⑤	14,486	최신 완결연도 2025	67	반도체군(FSC 5961 · 5962)

- 관세청 행은 「HS10 × 국가 × 월」 단위라서 분석에서는 HS6 × 국가 × 연 또는 HS6 × 연으로 합산해 쓴다(11 [6]). 숫자 변환 실패 · 완전 중복 · 키 중복 · 음수 금액은 모두 0 이다(11 [4]).
- 국산화개발품목은 같은 부품이 여러 사업에 반복 등재돼(중복 1회뿐인 부품 20,703개, 최대 57회) **원본 33,965와 고유 25,025는 다른 숫자**다. 그래서 규모는 원본 33,965 · 업무키 고유 25,025 · 부품관리번호 고유 12,788 을 나란히 쓴다(02 [3] · 13 [3]·[7]). 노트북 13 이 원본에서 같은 규칙을 다시 적용한 결과(25,025행 · 전자군 2,717행)는 DB 정제 표와 일치한다(13 [7]).

4. 유형별 처리 사례

유형	데이터	처리 전(원본)	처리 후(정제)	근거
결측	국내 조달계획	예산 칸이 빈 행 4,965	0 으로 채우지 않고 NULL. 합계는 분모에서 빼고 미기재 건수를 함께 적는다	04 [9]·[15]
결측	국산화개발품목	규격번호 결측 88.0% · 최종수정일 결측 74.2%	채우지 않고 분석 측에서 뺀다. 최종수정일은 채워진 6,865행이 모두 2021년이라 연도 측으로 쓰지 않는다	13 [5]·[14]
결측	국내 계약 업체 주소	시도로 바꿀 수 없는 첫 토큰 ** · 1 (각 1행)	시도 NULL — 추정하지 않음	04 [3]
중복	국산화개발품목	같은 사업 × 부품관리번호 반복(완전 중복 8,940행)	업무키 고유 25,025행 + 원본 행 수 dup_count 보존. 내용이 다른 충돌 0	02 [3] · 13 [7]
중복	국내조달 계약정보	계약번호 2024UMM1504 차수 01 이 2행	대표 1행, 나머지는 키 충돌(KEY_CONFLICT)로 제외 기록	04 [3]
중복	국내조달 입찰결과	같은 공고번호 + 차수 키에 여러 행	지우지 않고 유형 표시 — 복수 낙찰 108키 · 결과 상이 73키 · 동일 결과 반복 18키, 키마다 대표 1행	04 [7]·[15]
단위	관세청 금액	달러인지 천 달러인지 불분명	2024년 848620 수입 12,129,034,952 를 달러로 읽으면 121억 달러(한국 총수입의 1.9%), 천 달러면 12조 달러(총수입의 약 19배) → 달러 로 판정	01 [4]
단위	KRIT 정부지원금	차수마다 「억」 45 · 「억원」 20 · 「백만원」 20 · 없음 11	억 원 한 열로 통일(백만원 ÷ 100), 원문 · 단위 근거 보존. 없음 11행은 NULL	05 [3]
단위	국외 조달계획 API 금액	통화가 확인되지 않음	숫자로 담되 「미검증」 표시, 합산 금지 — 화면은 건수만	03 [4]
코드	국내조달 계약차수	원문 0 (837행)과 00 혼재	2자리로 통일 → 계약번호 × 차수 고유 43,111	12 [4] · 04 [3]
코드	HS 코드 길이	품목명 표에 5 · 7 · 9자리 코드	앞자리 0 누락이 아니다(0 으로 시작하는 코드 1,601행이 그대로 있음) → 0 을 채우지 않는다	01 [10]·[11]
코드	재고번호(NSN)	NSN · N/A · TBD 같은 자리표시가 섞임	숫자 13자리 9,970 · 영숫자 13자리 3,266 만 NSN, 자리표시 347 · 기타 32 는 NULL	03 [2]·[3]

유형	데이터	처리 전(원본)	처리 후(정제)	근거
코드	적용장비명	같은 장비의 띄어쓰기 · 표기가 다름 (예: 대포병탐지레이다 · 대포병탐지레이더)	기계적 정규화 + 변이 규칙 1개(레이다 → 레이더). 원문 843종 중 변이가 관측된 20묶음(원문 40)만 표준명 「후보」, 803종은 「미확인」	03 [5]·[6]·[16]
취인 행	관세청 수출입실적	호출마다 연간 총계행 1행씩(246행) — 상세행과 합치면 금액이 두 배	정제 표에서 분리. 총계행과 상세행 합계 대조 불일치 0	01 [3]·[5]
테스트	국내조달 계약정보	업체명이 정확히 조달테스트업체 I · 테스트업체1 인 행 6	자리표시(PPLACEHOLDER)로 제외. 「테스트」가 들어간 실제 업체 · 품명이 있어 키워드로는 거르지 않는다	04 [2]·[3]
테스트	국외조달 계약정보	업체명 TEST2 계약 6행	자리표시로 제외. 「TEST」가 들어간 실제 계약(시험 장비 등)은 남긴다	03 [7]·[8]
열 밀림	국내조달 입찰공고 · 입찰결과	공고 LCF0223 1 · 2차: 공고일자가 비고 계약방법 칸에 Y, 개찰결과 칸에 날짜	열 밀림(COL_SHIFT)으로 각 2행 제외. 나머지 입찰공고 10,840행은 형식 위반 0	04 [4]~[7]

이 밖에 열린재정 2027년 「미확정」 표시(05 [5]), KRIT 과제번호 재부여(키 충돌 30행 → 96행 고유, 05 [3]), 소요군 이름 표준화(03 [4]), KOSIS 잠점 표기로 잘린 월 16행 복원(06 [9])도 같은 원칙으로 처리했다.

5. 제외 행과 사유

제외 기록 표(`clean_excluded_row`)에는 모두 **23행**이 있다. 노트북 04 [15] 출력의 17행에, 노트북 실행 뒤 09-28 최종 점검 때 기록한 국외조달 조달계획(파일판) 6행을 더한 수다(로컬 실행 패키지의 DB 덤프로 확인할 수 있다).

사유 코드	뜻	원본 데이터	행 수
KEY_CONFLICT	같은 키가 둘 이상 — 대표 1행만 남김	국내조달 계약정보	1
COL_SHIFT	열 밀림 — 값이 옆 칸으로 밀림	국내조달 입찰공고	2
COL_SHIFT	열 밀림	국내조달 입찰결과	2
PLACEHOLDER	테스트 · 자리표시 행	국내조달 계약정보	6
PLACEHOLDER	테스트 계약	국외조달 계약정보	6
OTHER	필수값(집행유형) 결측	국외조달 조달계획(파일판)	1
KEY_CONFLICT	같은 판단번호의 별개 계획 — 대표 1행만 남김	국외조달 조달계획(파일판)	5

- 국외조달 조달계획(파일판)** 에서 빠진 원본 행(필수값 결측 1 · 대표가 아닌 중복 판단번호 5, 02 [6])은 노트북 02 의 적재 셀 (02 [11]) 출력이 저장돼 있지 않아, 09-28 최종 점검 때 DB 에서 직접 확인하고 제외 기록 표에 남겼다. 그래서 04 [15] 의 집계(17행)에는 나타나지 않는다.
- 관세청 총계행 246행**은 원본을 집계한 행이라 제외 기록 표가 아니라 검산식 「원본 294,420 = 상세 294,174 + 총계 246」 으로 확인한다(01 [21]).
- 빠지 않고 표시만 한 행**: 국산화개발품목 군급 4자리 아님 16행(군급 축에서만 제외, 13 [7]) · 국외 조달계획 API 적용장비명 공란 2,018행(03 [6]) · 품목순번 공란 842행(03 [3]) · 국내 조달계획 예산 미기재 4,965행(04 [9]). 이 행들은 정제 표에 그대로 있고, 쓰는 화면 · 분석에서만 따로 센다.

6. 한계와 남은 과제

노트북 끝의 「남은 일」 가운데 그 뒤에 해결된 것은 빠고, 지금도 남아 있는 것만 적었다.

1. **키워드·규칙으로 고른 값은 아직 '후보'다.** 국외조달 조달계획의 전자 관련 후보 392건(13.0%, 02 [7]), 국내 계약의 5분류와 전자·부품·방산 속성(43,105행 모두 「판단 보류」·「미확인」, 04 [15]), 예산 세부사업 묶음 후보(05 [5])는 표본 검수 전이다. 화면·결론에 확정값으로 쓰지 않는다.
2. **적용장비명 표준화는 일부만 됐다.** 원문 843종 중 803종이 「미확인」이다(03 [16]). 사람 검수나 방위사업청 용어사전 같은 근거가 있어야 표준명을 채울 수 있다. 괄호 안 파생형(예: 대표병탐지레이더)을 떼어 묶는 것은 뜻이 달라질 수 있어 하지 않았다.
3. **국외 조달계획 API의 금액은 통화를 검증하지 못했다.** 검증 전까지 「미검증」 표시를 유지하고 금액은 쓰지 않는다(03 [4]).
4. **대표 행 규칙 일부는 잠정이다.** 입찰결과 「결과 상이」 73키의 대표 행(먼저 나온 행, 04 [7])과 KRIT 공고 순서(예비 < 본공고 < 수정 < 재공고, 05 [2])는 팀 확인이 남아 있다.
5. **업체명 연결률이 낮다.** 방산업체 84곳 중 정확 일치 49·다중 2·미연결 33(연결률 58.3%), 국산화개발품목 업체 407곳 중 정확 일치 118·다중 12·미연결 277(29.0%)이다(04 [11]). 다중·미연결은 수동 검토 전이며, 이 연결을 쓸 때는 연결률을 함께 보고한다.
6. **예산 세부사업의 개편 연결은 일부만 확정됐다.** 국방기술개발 단위사업 안의 표기변경 9건만 확정이고, 승계 후보 5건·신설 8건은 공식 근거를 찾지 못했다(05 [13]).
7. **KOSIS 잠정치 판정은 갱신본에서 다시 해야 한다.** 지금 파일에서는 잠정 표기 행과 월이 잘린 행이 같지만, 고친 파서로 갱신본을 적재하면 이 등식이 성립하지 않는다(06 [10]).
8. **검산 출력 일부가 노트북에 저장돼 있지 않다.** 5장의 국외조달 조달계획 제외 6행은 적재 셀(02 [11]) 출력이 없어 노트북이 아니라 DB의 제외 기록 표로 확인한다. 다음 재실행 때 검산표 출력을 함께 저장한다.
9. **업체명 정규화 결과가 1곳 다르다.** 노트북 13의 간단 규칙은 404곳, 정제 표 기준은 403곳이다(13 [7]). 업체 단위 수치는 ±1 업체 오차를 안고 있다.

7. 부록 — 노트북 색인

노트북	다루는 데이터	만드는 표	검산
01_clean_customs	관세청 수출입실적·HS부호 마스터·HS 단위별 품목명·HSK 연계표	fact_customs_monthly 검증·dim_hs10 보강·clean_hsk_control	[21]
02_clean_localized_overseas_plan	국산화개발품목·국외조달 조달계획(파일판)	clean_dapa_localized_item·clean_d apa_overseas_plan	[13]
03_clean_overseas	국외 조달계획 OpenAPI·국외조달 계약·입찰결과	clean_dapa_overseas_* 3표·장비명 사전 ref_equipment_alias	[16]
04_clean_domestic	국내조달 계약·입찰공고·입찰결과·조달계획·군별 계약집행·방산업체	clean_dapa_contract·clean_dapa_bi d_*·clean_company 등 7표	[15]
05_clean_krit_budget	KRIT 부품국산화 공고·열린재정 세부사업 예산	clean_krit_task·clean_openfiscal_ program_* 2표	[13]
06_clean_kosis	KOSIS 방산 가동률·광공업생산지수	clean_kosis_* 2표	[9]

EDA 노트북 11~14는 표를 만들지 않고 원본 파일·정제 표를 읽기만 한다 — 11_eda_customs (관세청, 1만 건 데이터 ①)·13_eda_localized_item (국산화개발품목, 1만 건 데이터 ②)·14_eda_overseas_plan (국외 조달계획)·12_eda_contract (국내조달 계약, 부록 — 보조 데이터). 내용은 08_EDA-보고서 에 정리했다.